

# **DATA SCIENCE**

## **TEMA: CIBERSEGURIDAD**

**28/07/25**



**EQUIPO 16:**  
**ANALIA RIVERA**  
**BELÉN PELLEJERO**

**FUNDACIÓN**  
**YPF**

# CIBERSEGURIDAD

La ciberseguridad se refiere a cualquier tecnología, práctica y política para prevenir los ataques cibernéticos o mitigar su impacto.

Los ataques cibernéticos son acciones maliciosas dirigidas a sistemas informáticos, redes o dispositivos con el objetivo de robar, alterar o destruir información.

Estos ataques pueden afectar tanto a individuos como a empresas y gobiernos, causando pérdidas económicas, robo de identidad y daño a la reputación.



# TIPOS DE ATAQUES CIBERNÉTICOS



## **PHISHING**



Engaño para obtener datos personales

## **MALWARE**



Software malicioso como virus o ransomware

## **ATAQUES DDoS**





Saturación de servidores para interrumpir servicios

## **EXPLOITS**



Aprovechamiento de vulnerabilidad del sistema





**¿CÓMO PODEMOS  
ENTENDER Y  
ANTICIPAR  
LOS  
CIBERATAQUES?**



## Proyecto realizado en tres etapas:

### **PREENTREGA 2**



Análisis exploratorio de un dataset de ataques cibernéticos.

### **PREENTREGA 3**



Modelado supervisado para predecir el éxito del ataque.

### **PREENTREGA 4**




Modelado no supervisado (clustering).

**Todos los datasets utilizados son sintéticos, lo que implica ciertas limitaciones.**



## OBJETIVO DEL TRABAJO

- ◆ Aplicar técnicas de clustering para segmentar y entender patrones de ataques cibernéticos registrados en distintos niveles de gravedad, tipos de ataque, zonas geográficas y respuestas aplicadas.



# **PREENTREGA 2**

## **CONOCIENDO EL TERRENO**

## PREENTREGA 2 : ANÁLISIS EXPLORATORIO DEL DATASET

**FUENTE:** Kaggle - Incirbo

**NOMBRE DEL DATASET:** cybersecurity\_attacks

**VARIABLES CLAVES SELECCIONADAS:**

Fecha y hora del ataque

IP origen y destino

Tipo de ataque

Nivel de gravedad

Acción tomada

Geolocalización

El objetivo fue entender la estructura del dataset y preparar los datos para su análisis posterior.



# PREENTREGA 2 : ANÁLISIS EXPLORATORIO DEL DATASET

|   | Timestamp           | Source IP Address | Destination IP Address | Source Port | Destination Port | Protocol | Packet Length | Packet Type | Traffic Type | Payload Data                                      | ... | Action Taken | Severity Level | User Information | Device Information                                | Network Segment | Geo-location Data  | Proxy Information | Firewall Logs | IDS/IPS Alerts | Log Source |
|---|---------------------|-------------------|------------------------|-------------|------------------|----------|---------------|-------------|--------------|---------------------------------------------------|-----|--------------|----------------|------------------|---------------------------------------------------|-----------------|--------------------|-------------------|---------------|----------------|------------|
| 0 | 2023-05-30 06:33:58 | 103.216.15.12     | 84.9.164.252           | 31225       | 17616            | ICMP     | 503           | Data        | HTTP         | Qui natus odio asperiores nam. Optio nobis ius... | ... | Logged       | Low            | Reyansh Dugal    | Mozilla/5.0 (compatible; MSIE 8.0; Windows NT ... | Segment A       | Jamshedpur, Sikkim | 150.9.97.135      | Log Data      | NaN            | Server     |
| 1 | 2020-08-26 07:08:30 | 78.199.217.198    | 66.191.137.154         | 17245       | 48166            | ICMP     | 1174          | Data        | HTTP         | Aperiam quos modi officis veritatis rem. Omni...  | ... | Blocked      | Low            | Sumer Rana       | Mozilla/5.0 (compatible; MSIE 8.0; Windows NT ... | Segment B       | Bilaspur, Nagaland | NaN               | Log Data      | NaN            | Firewall   |
| 2 | 2022-11-13 08:23:25 | 63.79.210.48      | 198.219.82.17          | 16811       | 53600            | UDP      | 306           | Control     | HTTP         | Perferendis sapiente vitae soluta. Hic delectu... | ... | Ignored      | Low            | Himmat Karpe     | Mozilla/5.0 (compatible; MSIE 9.0; Windows NT ... | Segment C       | Bokaro, Rajasthan  | 114.133.48.179    | Log Data      | Alert Data     | Firewall   |
| 3 | 2023-07-02 10:38:46 | 163.42.196.10     | 101.228.192.255        | 20018       | 32534            | UDP      | 385           | Data        | HTTP         | Totam maxime beatae expedita explicabo porro l... | ... | Blocked      | Medium         | Fateh Kibe       | Mozilla/5.0 (Macintosh; PPC Mac OS X 10_11_5; ... | Segment B       | Jaunpur, Rajasthan | NaN               | NaN           | Alert Data     | Firewall   |
| 4 | 2023-07-16 13:11:07 | 71.166.185.76     | 189.243.174.238        | 6131        | 26646            | TCP      | 1462          | Data        | DNS          | Odit nesciunt dolorem nisi iste iusto. Animi v... | ... | Blocked      | Low            | Dhanush Chad     | Mozilla/5.0 (compatible; MSIE 5.0; Windows NT ... | Segment C       | Anantapur, Tripura | 149.6.110.119     | NaN           | Alert Data     | Firewall   |

# PREENTREGA 2 : ANÁLISIS EXPLORATORIO DEL DATASET

## Limpieza y transformación

- Se eliminaron o reemplazaron valores nulos.
- Renombrado de columnas para mayor claridad.
- Codificación de variables categóricas (tipo de ataque, gravedad, etc.) usando LabelEncoder.
- Normalización de datos geográficos para facilitar el análisis posterior.
- Visualización de patrones de ataques y acciones tomadas.
- Detección y tratamiento de outliers (Winsorización y Z-Score).
- Preparación de los datos para futuros modelos.



## **PREENTREGA 2 : ANÁLISIS EXPLORATORIO DEL DATASET**





# **Visualizaciones y patrones iniciales**



# PREENTREGA 2 : ANÁLISIS EXPLORATORIO DEL DATASET

Gráfico de barras e histograma para ver la frecuencia de tipos de ataque.



Attack Type


**DDoS** 13428

**Malware** 13307

**Intrusion** 13265


# PREENTREGA 2 : ANÁLISIS EXPLORATORIO DEL DATASET

**Distribución de tipos de ataque según nivel de gravedad.**



# PREENTREGA 2 : ANÁLISIS EXPLORATORIO DEL DATASET

## Gráfico de datos de geolocalización





## PREENTREGA 2 : ANÁLISIS EXPLORATORIO DEL DATASET

### Hallazgos



Malware y phishing fueron los ataques más comunes.



Los ataques con mayor gravedad se concentraron en ciertas regiones.





**PREENTREGA 3**  
**¿EL ATAQUE SERÁ**  
**EXITOSO?**



## PREENTREGA 3 : MODELO SUPERVISADO

FUENTE: Kaggle

NOMBRE DEL DATASET:

cybersecurity\_large\_synthesized\_data

VARIABLES CLAVES SELECCIONADAS:

Tipo de ataque, Industria, Países, outcome, data comprometida, severidad, método de mitigación, fecha y hora, herramienta de seguridad usada.

El objetivo es ver cuáles fueron los países que más ataques tuvieron y de qué tipo, cuál fue el horario más buscado para el ataque y la industria más afectada. Y por último si el ataque fue exitoso o no.


# PREENTREGA 3 : MODELADO SUPERVISADO

|   | attack_type      | target_system | outcome | timestamp                  | attacker_ip     | target_ip       | data_compromised_GB | attack_duration_min | security_tools_used | user_role     | location  | attack_severity | industry   | response_time_min | mitigation_method |
|---|------------------|---------------|---------|----------------------------|-----------------|-----------------|---------------------|---------------------|---------------------|---------------|-----------|-----------------|------------|-------------------|-------------------|
| 0 | Phishing         | Cloud Service | Failure | 2024-04-03 11:13:15.083419 | 21.166.79.4     | 23.20.50.78     | 15.31               | 300                 | Firewall            | Employee      | Australia | 2               | Energy     | 164               | Containment       |
| 1 | DDoS             | Email Server  | Success | 2024-02-03 20:51:56.083463 | 187.180.150.169 | 34.160.58.218   | 65.05               | 242                 | Endpoint Detection  | Admin         | Brazil    | 10              | Retail     | 64                | Reset Credentials |
| 2 | Zero-Day Exploit | Cloud Service | Success | 2024-07-19 18:40:05.083472 | 57.161.159.140  | 213.142.125.206 | 48.99               | 120                 | Firewall            | External User | Germany   | 7               | Finance    | 87                | Quarantine        |
| 3 | SQL Injection    | Email Server  | Failure | 2023-12-08 00:54:17.083478 | 207.108.16.104  | 4.104.193.49    | 16.29               | 286                 | MFA                 | Employee      | Russia    | 3               | Healthcare | 23                | Patch             |
| 4 | Zero-Day Exploit | IoT Device    | Failure | 2024-07-23 05:38:20.083483 | 98.122.15.31    | 57.66.53.194    | 87.66               | 4                   | Firewall            | Contractor    | UK        | 6               | Finance    | 129               | Containment       |


## PREENTREGA 3 : MODELADO SUPERVISADO

- Limpieza y transformación de datos.
- Codificación categórica (OneHotEncoder).
- Balanceo de clases con SMOTE y SMOTETomek.
- Selección de variables con SelectKBest.
- Modelado con SVM, Random Forest y XGBoost.
- Optimizado con GridSearchCV y evaluación con F1 Macro.

# PREENTREGA 3 : MODELADO SUPERVISADO



Mapa de calor de ataques por tipo y país



Distribución de severidad de ataque por industria

## PREENTREGA 3 : MODELADO SUPERVISADO

Se utilizó XGBoost, un algoritmo de ensamble basado en árboles que combina múltiples modelos simples y los optimiza de forma secuencial.


Su ventaja principal es la precisión, eficiencia y capacidad de generalización, incluso en datasets complejos como este de ciberseguridad.

Se crea un primer árbol de decisión, luego, cada nuevo árbol corrige los errores del anterior. Así, el modelo va aprendiendo de forma secuencial e inteligente. Se ajustan pesos y errores usando gradientes, como en el aprendizaje profundo.

## **PREENTREGA 3 : MODELADO SUPERVISADO**

- ◆ Como análisis complementario, utilizamos el modelo Prophet para visualizar la evolución de los ataques cibernéticos a lo largo del tiempo.


## PREENTREGA 3 : MODELADO SUPERVISADO



En el gráfico se observa la cantidad diaria de ataques, representada por puntos negros, y una línea azul que muestra la tendencia estimada por el modelo.

El área azul claro representa el intervalo de confianza del modelo, es decir, el rango dentro del cual se espera que se mantenga el número de ataques en los próximos días.

## PREENTREGA 3 : MODELADO SUPERVISADO



Se puede observar que, si bien existe cierta variación diaria, la tendencia general se mantiene relativamente estable, en un promedio de aproximadamente 270 ataques por día.


Este tipo de análisis temporal permite anticipar posibles cambios en el volumen de ataques y complementar los modelos de predicción de éxito (outcome) con una perspectiva temporal del riesgo.



# PREENTREGA 3 : MODELADO SUPERVISADO

## CONCLUSIÓN

- ◆ A partir del análisis exploratorio, detectamos que EE.UU. es el país con más ataques, especialmente del tipo fuerza bruta, afectando industrias como salud, finanzas y educación. Esto motivó el desarrollo de modelos de clasificación para predecir si un ataque será exitoso o no. Luego de comparar SVM, Random Forest y XGBoost, este último obtuvo el mejor F1-score tras optimización y balanceo, demostrando ser el más robusto frente al desbalanceo de clases y la alta dimensionalidad del dataset.



# **PREENTREGA 4**

## **DESCUBRIENDO LO OCULTO**

## PREENTREGA 4: MODELADO NO SUPERVISADO (CLUSTERING)

Finalmente, abordamos el problema desde un enfoque no supervisado. Ya sin conocer el resultado del ataque, quisimos agrupar patrones similares.

## PREENTREGA 4: MODELADO NO SUPERVISADO (CLUSTERING)

Usamos técnicas de clustering para identificar posibles grupos de ataques:

Preprocesamiento con escalado y codificación numérica.


KMeans y DBSCAN como algoritmos de agrupamiento.

Validación con Silhouette Score HDBSCAN (0.396: agrupamiento débil).

Escalado de datos (Z-score).

Visualización de grupos y análisis.

# PREENTREGA 4: MODELADO NO SUPERVISADO (CLUSTERING)



# PREENTREGA 4: MODELADO NO SUPERVISADO (CLUSTERING)

## Algoritmos aplicados:

- ◆ El objetivo fue segmentar los registros de ataques en grupos que compartieran características similares.

## Modelos utilizados:

KMeans: Agrupación por cercanía a centroides.

DBSCAN: Agrupación por densidad (mejor para detectar outliers y formas irregulares).

# PREENTREGA 4: MODELADO NO SUPERVISADO (CLUSTERING)

## Implementación

◆ Se seleccionaron variables numéricas procesadas previamente. ◆


Con KMeans, se evaluó el número óptimo de clusters usando el método del codo.

Con DBSCAN, se probaron distintos valores de eps y min\_samples.

# PREENTREGA 4: MODELADO NO SUPERVISADO (CLUSTERING)


## Método del codo

```
wcss = []  
for i in range(1,10):  
    km = KMeans(n_clusters=i, init='k-means++', max_iter=300, random_state=42)  
    km.fit(X_scaled)  
    wcss.append(km.inertia_)  
plt.plot(range(1,10),wcss)  
plt.title('Elbow Method')  
plt.xlabel('Number of clusters')  
plt.ylabel('WCSS')  
plt.show()
```





# PREENTREGA 4: MODELADO NO SUPERVISADO (CLUSTERING)



## PREENTREGA 4: MODELADO NO SUPERVISADO (CLUSTERING)

### Observación

DBSCAN identificó varios registros como ruido, revelando patrones distintos a los detectados por KMeans.

# PREENTREGA 4: MODELADO NO SUPERVISADO (CLUSTERING)

## Conclusiones

KMeans fue más útil para segmentar los datos de forma clara y reproducible.

DBSCAN resultó sensible a los parámetros y generó mucho ruido inicialmente.

La visualización en PCA ayudó a validar los resultados de forma intuitiva.

Este análisis puede ayudar a los equipos de ciberseguridad a reaccionar más rápido y con mejor información.

# PREENTREGA 4: MODELADO NO SUPERVISADO (CLUSTERING)



El método HDBSCAN permitió:

- Detectar agrupamientos de distinta densidad, que otros métodos no captaban.
- Evitar la necesidad de elegir manualmente un eps.
- Identificar outliers con mayor precisión.

La visualización mostró clusters más coherentes, y el Silhouette Score obtenido fue de 0.3964, superior a DBSCAN tradicional.

Este método resulta prometedor para datos reales con ruido o variabilidad alta.

# Limitaciones del Dataset Sintético

- No refleja patrones reales de amenazas cibernéticas.
- Las relaciones entre variables pueden estar generadas artificialmente.
- Resultados no generalizables directamente a entornos reales.

# ¿Por qué no hay muchos datasets abiertos de ciberseguridad?

- Confidencialidad y sensibilidad de los datos.
- Riesgos de seguridad.
- Falta de estandarización.
- Costos y esfuerzos de anonimización
- Intereses comerciales.

# ¿Cómo se soluciona esto en proyectos académicos o de aprendizaje?

- Datasets sintéticos
- Datasets públicos pero limitados
- Simulación con herramientas como Wireshark, Snort, Zeek (Bro)

# CONCLUSIONES

- Se desarrolló un flujo completo de análisis, preprocesamiento y modelado.
- El uso de datos sintéticos permitió practicar técnicas de Machine Learning.
- Para datos reales:
  - Es clave el acceso a logs completos, datos de red y tiempos.
  - Se requiere una mayor robustez en la limpieza y validación.
  - La ciberseguridad es un ámbito donde los modelos deben actualizarse constantemente.





**¡MUCHAS GRACIAS!**